## بسمه تعالى

موضوع: گزارش مینی پروژه اول (ماشین لرنینگ)

نام و نام خانوادگی: محمدعرفان مومنی نسب

شماره دانشجویی: ٤٠٢١٦٣١٢

نام دانشگاه: دانشگاه جامع انقلاب اسلامی

نام استاد درس: جناب آقای دکتر علیاری

نام استاد یار درس: جناب آقای مهندس محمدجواد احمدی

# ۳ سوال سوم

- ۱. به ااین پیوند مراجعه کرده و یک دیتاست مربوط به «بیماری قلبی» را دریافت کرده و توضیحات مختصری در مورد هدف و ویژگیهای آن بنویسید. فایل دانلودشدهٔ دیتاست را روی گوگلدرایو خود قرار داده و با استفاده از دستور gdown آن را در محیط گوگلکولب بارگذاری کنید.
- ۲. ضمن توجه به محل قرارگیری هدف و ویژگیها، دیتاست را بهصورت یک دیتافریم درآورده و با استفاده از دستورات پایتونی، ۱۰۰ نمونهداده مربوط به کلاس «۱» و ۱۰۰ نمونهداده مربوط به کلاس «۰» را در یک دیتافریم جدید قرار دهید و در قسمتهای بعدی با این دیتافریم جدید کار کنید.
- ۳. با استفاده از حداقل دو طبقهبند آمادهٔ پایتون و در نظر گرفتن فراپارامترهای مناسب، دو کلاس موجود در دیتاست را از هم تفکیک کنید. نتیجهٔ دقت آموزش و ارزیابی را نمایش دهید.
- ۴. در حالت استفاده از دستورات آمادهٔ سایکیتارن، آیا راهی برای نمایش نمودار تابع اتلاف وجود دارد؟ پیادهسازی
- ۵. یک شاخصهٔ ارزیابی (غیر از Accuracy) تعریف کنید و بررسی کنید که از چه طریقی می توان این شاخص جدید را در ارزیابی دادههای تست نمایش داد. پیادهسازی کنید.

# **Part 1: Data Preparation**

Objective: Create a new balanced dataset with 100 samples each from classes '0' (no heart disease) and '1' (heart disease) from the provided dataset.

Method: Used pandas to filter and randomly sample 100 instances from each class, resulting in a balanced dataset of 200 samples.

```
heart_disease_data = pd.read_csv('/content/drive/My_Drive/heart_disease_health_indicators.csv')
class_1_samples = heart_disease_data[heart_disease_data['HeartDiseaseorAttack'] == 1].sample(n=100, random_state=11)
combined_samples = pd.concat([class_1_samples, class_0_samples])
combined_samples.reset_index(drop=True, inplace=True)
combined_samples.head() # Displaying the first few rows of the new dataframe
   HeartDiseaseorAttack HighBP HighChol CholCheck BMI Smoker Stroke Diabetes PhysActivity Fruits ... AnyHealthcare NoDocbcCost GenHlth MentHlth PhysHlth
                                                 1 29
5 rows × 22 columns
```

# **Part 2: Model Training and Evaluation**

Objective: Train Logistic Regression and Random Forest Classifier models and evaluate their performance.

### Approach:

Data was split into training and testing sets.

Logistic Regression and Random Forest models were trained.

Accuracy was chosen as the evaluation metric.

### **Results:**

Random Forest Classifier Accuracy: 0.616666666666667%

Issues Encountered: Received a convergence warning for Logistic Regression.

#### **Resolution:**


Suggested increasing the number of iterations (max\_iter) and performing feature scaling using StandardScaler.

## **Part 3: Loss Function Visualization**

**Objective:** Implement a method to visualize the loss function over iterations.

**Approach:** Custom implementation of logistic regression using gradient descent to enable loss tracking.

**Outcome:** Provided a script for a basic implementation of logistic regression, including a plot of the loss function over iterations.



# **Part 4: Alternative Evaluation Metric**

**Objective:** Define and implement an evaluation index other than accuracy.

Metric Chosen: Area Under the Receiver Operating Characteristic Curve (AUC-ROC).


## Implementation:

Calculated AUC-ROC for both models.

Plotted ROC curves to visualize performance.

### **Results:**

Provided Python script to calculate and plot AUC-ROC for Logistic Regression and Random Forest Classifier.



# (1):

The dataset provided appears to focus on various health indicators and their potential relationship with heart disease or attacks. Here's a brief overview based on the first few rows:

**HeartDiseaseorAttack:** This column seems to be a binary indicator (0 or 1) denoting whether the individual has had a heart disease or attack.

**HighBP, HighChol, CholCheck:** These columns indicate whether the individual has high blood pressure, high cholesterol, and if they have had their cholesterol checked, respectively.

BMI: Body Mass Index of the individuals.

Smoker, Stroke, Diabetes: Indicates whether the individual is a smoker, has had a stroke, or has diabetes.

**PhysActivity, Fruits, Veggies, HvyAlcoholConsump:** These columns appear to record lifestyle factors such as physical activity, fruit and vegetable consumption, and heavy alcohol consumption.

**AnyHealthcare, NoDocbcCost:** Accessibility to healthcare and whether cost has been a barrier to seeing a doctor.

**GenHlth, MentHlth, PhysHlth, DiffWalk:** General health status, mental health status, physical health status, and difficulty in walking.

**Sex, Age, Education, Income**: Demographic information including gender, age group, education level, and income bracket.

This dataset likely aims to study the correlation between these factors and the risk of heart disease or attacks.